

Frédéric **Andrian**

Ingénieur IA générative · Agents et RAG

(+33) 769875327 | fredericj.andrian@gmail.com | AndriantsehenoFrederic |
FredericAndriantseheno

Profil

Jeune diplômé de l'ENSC, école de Bordeaux INP, spécialisé en intelligence artificielle et sciences cognitives, je viens de terminer mon stage de fin d'études à INRIA Bordeaux et suis disponible dès que possible. À l'INRIA, j'ai développé une application IA de bout en bout associant un agent multi-étapes, des services Python/FastAPI, un pipeline RAG, MongoDB et une interface React/Next.js. J'ai également conçu ses prompts et ses outils, évalué plusieurs LLM et contribué à un article scientifique. Je souhaite poursuivre le développement de solutions d'IA utiles et robustes.

Expériences professionnelles

INRIA — Bordeaux, France

Stagiaire ingénieur de recherche en IA — Mars 2026 – Septembre 2026

- Conception et développement en autonomie d'une application et d'un agent IA multi-étapes pour aider les chercheurs à trouver des articles scientifiques.
- Construction de l'agent en Python sans framework d'orchestration, avec API OpenAI, prompts, appels d'outils et gestion de la mémoire et du contexte.
- Développement d'un pipeline RAG avec chunking, embeddings et recherche sémantique dans ChromaDB, associé à une persistance MongoDB.
- Développement d'API REST Python/FastAPI documentées avec OpenAPI et d'une interface React/Next.js pour l'utilisation de l'agent.
- Automatisation de la collecte de métadonnées d'articles scientifiques en ligne et transmission des résultats de tâches cron par webhooks.
- Conteneurisation des composants avec Docker, versionnement sous Git et mise en place d'une CI/CD sur GitHub.
- Déploiement et serving de LLM avec vLLM sur une infrastructure HPC équipée de GPU NVIDIA et utilisation de Slurm pour les expérimentations.
- Évaluation de Qwen, Gemma, GLM et de plusieurs quantifications selon la qualité, la latence et le contexte, avec rédaction en cours d'un article scientifique.
- Gestion d'une application utilisant des modèles locaux avec LM Studio sur Mac Studio, avec installation et configuration des modèles.
- Évaluation d'OpenClaw dans un environnement Docker isolé et analyse des risques liés à l'accès autonome aux outils et aux fichiers.

Université Karunya — Coimbatore, Inde

Stagiaire de recherche en apprentissage par renforcement — Juin 2025 – Sept. 2025

- Développement d'un modèle d'apprentissage par renforcement et de son environnement d'entraînement pour la navigation autonome d'un robot hospitalier.
- Déploiement et optimisation du logiciel et du modèle sur Raspberry Pi pour des tests en conditions réelles.

Compétences

Développement	Python, JavaScript, C#, .NET, Java, FastAPI, React, Next.js, Node.js, API REST, OpenAPI
IA générative et agents	LLM, vLLM, API OpenAI, LangChain, prompts, agents multi-étapes, RAG, embeddings, ChromaDB
Data et Machine Learning	Pandas, scikit-learn, SQL, MongoDB, PyTorch, TensorFlow, Deep Learning, RL
Évaluation de LLM	Protocoles expérimentaux, quantification, latence, TTFT, qualité, taille du contexte
Génie logiciel et outils	Linux, Docker, Git/GitHub, CI/CD, Slurm, environnement HPC
Langues	Français natif, anglais courant avec IELTS 7,5, espagnol notions

Formation

ENSC (École nationale supérieure de cognitique, Bordeaux INP) — Bordeaux, France

Diplôme d'ingénieur en intelligence artificielle et sciences cognitives — 2023 – 2026

- Formation en informatique, génie logiciel, intelligence artificielle et sciences cognitives, incluant l'interaction humain-machine, l'ergonomie et l'expérience utilisateur, avec une spécialisation en LLM, TALN et apprentissage profond.