

Frédéric **Andrian**

Ingénieur IA appliquée · LLM Infra

(+33) 769875327 | fredericj.andrian@gmail.com | AndriantsehenoFrederic |
FredericAndriantseheno

Profil

Jeune diplômé de l'ENSC, école de Bordeaux INP, spécialisé en intelligence artificielle et sciences cognitives, je viens de terminer mon stage de fin d'études à INRIA Bordeaux et suis disponible dès que possible. À l'INRIA, j'ai développé une application IA de bout en bout associant un agent multi-étapes, des services Python/FastAPI, un pipeline RAG, MongoDB et une interface React/Next.js. J'ai également conçu ses prompts et ses outils, évalué plusieurs LLM et contribué à un article scientifique. Je souhaite poursuivre le développement de solutions d'IA utiles et robustes.

Expériences professionnelles

INRIA — équipe Mnémosyne Bordeaux, France

Stagiaire ingénieur de recherche en IA Mars 2026 – Septembre 2026

- Conception en autonomie, avec le suivi de mes encadrants, d'une application et d'un agent IA multi-étapes répondant au besoin d'aider les chercheurs à trouver des articles scientifiques.
- Développement d'un backend Python/FastAPI avec API REST documentées avec OpenAPI et persistance des documents et métadonnées dans MongoDB.
- Construction de l'agent sans framework d'orchestration avec intégration de l'API OpenAI, conception de prompts et gestion des outils, de l'état, de la mémoire et du contexte.
- Mise en œuvre d'un pipeline RAG avec chunking, embeddings, recherche sémantique et base vectorielle ChromaDB.
- Automatisation de la collecte de métadonnées d'articles scientifiques disponibles en ligne et transmission des résultats de tâches cron par webhooks.
- Gestion d'une application web conteneurisée permettant d'utiliser des LLM installés localement avec LM Studio sur un Mac Studio, avec installation et configuration des modèles.
- Utilisation de vLLM pour lancer et servir des modèles sur une infrastructure HPC équipée de GPU NVIDIA.
- Évaluation de Qwen, Gemma et GLM et de plusieurs quantifications sur infrastructure HPC avec Slurm selon la latence, le TTFT, la qualité et la taille du contexte.
- Conteneurisation de composants avec Docker, versionnement avec Git et mise en place d'une CI/CD sur GitHub.
- Évaluation d'OpenClaw dans un environnement Docker isolé afin d'étudier les risques liés à l'accès de l'agent aux outils et aux fichiers.
- Définition du protocole expérimental, analyse des résultats et rédaction en cours d'un article scientifique comparant les modèles.

Université Karunya Coimbatore, Inde

Stagiaire ingénieur de recherche en apprentissage par renforcement Juin 2025 – Sept. 2025

- Développement d'un modèle d'apprentissage par renforcement et de son environnement d'entraînement pour la navigation autonome d'un robot hospitalier.
- Déploiement et optimisation du logiciel et du modèle sur Raspberry Pi pour des tests en conditions réelles.

Compétences

Développement	Python, JavaScript, C#, .NET, Java, FastAPI, React, Next.js, Node.js, API REST, OpenAPI
IA générative et agents	LLM, vLLM, API OpenAI, LangChain, prompts, agents multi-étapes, RAG, embeddings, ChromaDB
Data et Machine Learning	Pandas, scikit-learn, SQL, MongoDB, PyTorch, TensorFlow, Deep Learning, RL
Évaluation de LLM	Protocoles expérimentaux, quantification, latence, TTFT, qualité, taille du contexte
Génie logiciel et outils	Linux, Docker, Git/GitHub, CI/CD, Slurm, environnement HPC
Langues	Français natif, anglais courant avec IELTS 7,5, espagnol notions

Formation

ENSC (École nationale supérieure de cognitique, Bordeaux INP) Bordeaux, France

Diplôme d'ingénieur en intelligence artificielle et sciences cognitives 2023 – 2026

- Formation en informatique, génie logiciel, intelligence artificielle et sciences cognitives, incluant l'interaction humain-machine, l'ergonomie et l'expérience utilisateur, avec une spécialisation en LLM, TALN et apprentissage profond.