

Frédéric **Andrian**

Ingénieur IA

(+33) 769875327 | fredericj.andrian@gmail.com | AndriantsehenoFrederic |
FredericAndriantseheno

Profil

Jeune diplômé de l'ENSC, école de Bordeaux INP, spécialisé en intelligence artificielle et sciences cognitives, je viens de terminer mon stage de fin d'études à INRIA Bordeaux et suis disponible dès que possible. À l'INRIA, j'ai développé une application IA de bout en bout associant un agent multi-étapes, des services Python/FastAPI, un pipeline RAG, MongoDB et une interface React/Next.js. J'ai également conçu ses prompts et ses outils, évalué plusieurs LLM et contribué à un article scientifique. Je souhaite poursuivre le développement de solutions d'IA utiles et robustes.

Expériences professionnelles

INRIA — Bordeaux, France

Stagiaire ingénieur de recherche en IA — Mars 2026 – Septembre 2026

- Conception en autonomie d'une application et d'un agent IA multi-étapes répondant au besoin d'aider les chercheurs à trouver des articles scientifiques.
- Construction de l'agent sans framework d'orchestration avec intégration de l'API OpenAI, conception de prompts et gestion des outils, de l'état, de la mémoire et du contexte.
- Mise en œuvre d'un pipeline RAG avec chunking, embeddings, recherche sémantique et base vectorielle ChromaDB.
- Développement d'un backend Python/FastAPI avec API REST documentées avec OpenAPI et persistance des documents et métadonnées dans MongoDB.
- Développement d'une interface React/Next.js permettant aux chercheurs d'interagir avec l'agent et ses différents outils.
- Automatisation de la collecte de métadonnées d'articles scientifiques disponibles en ligne et transmission des résultats de tâches cron par webhooks.
- Gestion d'une application web conteneurisée permettant d'utiliser des LLM installés localement avec LM Studio sur un Mac Studio, avec installation et configuration des modèles.
- Utilisation de vLLM pour lancer et servir des modèles sur une infrastructure HPC équipée de GPU NVIDIA.
- Évaluation de Qwen, Gemma et GLM et de plusieurs quantifications avec Slurm selon la latence, le TTFT, la qualité et la taille du contexte.
- Définition du protocole expérimental, analyse des résultats et rédaction en cours d'un article scientifique comparant les modèles.
- Conteneurisation de composants avec Docker, versionnement avec Git et mise en place d'une CI/CD sur GitHub.

Université Karunya — Coimbatore, Inde

Stagiaire ingénieur de recherche en apprentissage par renforcement — Juin 2025 – Sept. 2025

- Développement d'un modèle d'apprentissage par renforcement et de son environnement d'entraînement pour la navigation autonome d'un robot hospitalier.
- Déploiement et optimisation du logiciel et du modèle sur Raspberry Pi pour des tests en conditions réelles.

Compétences

Développement	Python, JavaScript, C#, .NET, Java, FastAPI, React, Next.js, Node.js, API REST, OpenAPI
IA générative et agents	LLM, vLLM, API OpenAI, LangChain, prompts, agents multi-étapes, RAG, embeddings, ChromaDB
Data et Machine Learning	Pandas, scikit-learn, SQL, MongoDB, PyTorch, TensorFlow, Deep Learning, RL
Évaluation de LLM	Protocoles expérimentaux, quantification, latence, TTFT, qualité, taille du contexte
Génie logiciel et outils	Linux, Docker, Git/GitHub, CI/CD, Slurm, environnement HPC
Langues	Français natif, anglais courant avec IELTS 7,5, espagnol notions

Formation

ENSC (École nationale supérieure de cognitique, Bordeaux INP) — Bordeaux, France

Diplôme d'ingénieur en intelligence artificielle et sciences cognitives — 2023 – 2026

- Formation en informatique, génie logiciel, intelligence artificielle et sciences cognitives, incluant l'interaction humain-machine, l'ergonomie et l'expérience utilisateur, avec une spécialisation en LLM, TALN et apprentissage profond.