

# Frédéric **Andrian**

Ingénieur informatique · HPC, intégration et déploiement

(+33) 769875327 | fredericj.andrian@gmail.com | AndriantsehenoFrederic |
FredericAndriantseheno

## Profil

Jeune diplômé de l'ENSC, école de Bordeaux INP, spécialisé en intelligence artificielle et sciences cognitives, je suis disponible dès que possible. À l'INRIA, j'ai utilisé des ressources HPC avec Slurm pour déployer des LLM via vLLM sur GPU NVIDIA et comparer leurs performances. J'y ai également développé une application et un agent IA en Python, conteneurisé des composants avec Docker et mis en place une CI/CD sur GitHub. Je souhaite orienter mon parcours vers le calcul haute performance et approfondir l'intégration, le déploiement et la reproductibilité des workflows logiciels au service de la recherche scientifique.

## Expériences professionnelles

### INRIA – Équipe Mnémosyne — Bordeaux, France

Stagiaire ingénieur de recherche en IA — Mars 2026 – Septembre 2026

- Conteneurisation de composants avec Docker, mise en place d'une CI/CD sur GitHub et versionnement du code avec Git.
- Utilisation de ressources HPC avec Slurm pour les expérimentations, avec installation, configuration et serving de LLM via vLLM sur GPU NVIDIA.
- Définition d'un protocole expérimental pour comparer Qwen, Gemma et GLM selon la qualité des réponses, la latence, le TTFT et la taille du contexte.
- Évaluation de plusieurs quantifications pour analyser les compromis entre qualité et performances selon les environnements d'exécution.
- Analyse des résultats expérimentaux et rédaction en cours d'un article scientifique sur la comparaison de modèles de langage pour notre cas d'usage.
- Conception et développement en autonomie d'une application et d'un agent IA pour la recherche d'articles scientifiques, à partir des besoins définis avec mon tuteur.
- Développement de l'agent en Python sans framework d'orchestration, avec appels d'outils, gestion de la mémoire et du contexte, et intégration de l'API OpenAI.
- Intégration de services Python/FastAPI, d'API REST documentées avec OpenAPI, d'un pipeline RAG, de MongoDB et d'une interface React/Next.js.
- Automatisation en Python de la collecte de métadonnées d'articles scientifiques en ligne et transmission des résultats de tâches cron par webhooks.
- Gestion d'une application utilisant des LLM exécutés localement via LM Studio sur Mac Studio, avec installation et configuration des modèles.
- Évaluation d'OpenClaw dans un environnement Docker isolé et analyse des risques liés aux accès autonomes aux outils et aux fichiers.

### Université Karunya — Coimbatore, Inde

Stagiaire de recherche en apprentissage par renforcement — Juin 2025 – Sept. 2025

- Développement d'un modèle d'apprentissage par renforcement et de son environnement d'entraînement pour la navigation autonome d'un robot hospitalier.
- Déploiement et optimisation du logiciel et du modèle sur Raspberry Pi pour des tests en conditions réelles.

## Compétences

| | |
|---|---|
| **Développement** | Python, JavaScript, C#, .NET, Java, FastAPI, React, Next.js, Node.js, API REST, OpenAPI |
| **IA générative et agents** | LLM, vLLM, API OpenAI, LangChain, prompts, agents multi-étapes, RAG, embeddings, ChromaDB |
| **Data et Machine Learning** | Pandas, scikit-learn, SQL, MongoDB, PyTorch, TensorFlow, Deep Learning, RL |
| **Évaluation de LLM** | Protocoles expérimentaux, quantification, latence, TTFT, qualité, taille du contexte |
| **Génie logiciel et outils** | Linux, Docker, Git/GitHub, CI/CD, Slurm, environnement HPC |
| **Langues** | Français natif, anglais courant avec IELTS 7,5, espagnol notions |

## Formation

### ENSC (École nationale supérieure de cognitique, Bordeaux INP) — Bordeaux, France

Diplôme d'ingénieur en intelligence artificielle et sciences cognitives — 2023 – 2026

- Formation en informatique, génie logiciel, intelligence artificielle et sciences cognitives, incluant l'interaction humain-machine, l'ergonomie et l'expérience utilisateur, avec une spécialisation en LLM, TALN et apprentissage profond.