

Frédéric **Andrian**

Ingénieur IA · Agents et RAG

(+33) 769875327 | fredericj.andrian@gmail.com | AndriantsehenoFrederic |
FredericAndriantseheno

Profil

Jeune diplômé de l'ENSC, école de Bordeaux INP, je suis disponible dès que possible. À l'INRIA, j'ai transformé un besoin de recherche documentaire en une application complète intégrant un agent IA, un pipeline RAG, une base vectorielle, des API et une interface utilisateur. J'ai conçu les prompts, les outils, la mémoire et la gestion du contexte, puis évalué la qualité de la solution. Autonome et attentif aux usages, je souhaite transposer cette expérience à l'écosystème Copilot Studio, Power Automate et Microsoft 365 afin de développer des agents utiles aux équipes métier et d'accompagner leur adoption.

Expériences professionnelles

INRIA — Bordeaux, France

Stagiaire ingénieur de recherche en IA — Mars 2026 – Septembre 2026

- Analyse d'un besoin de recherche d'articles scientifiques et conception en autonomie d'une application intégrant un agent IA multi-étapes.
- Construction de l'agent sans framework d'orchestration avec API OpenAI, conception de prompts et gestion des outils, de l'état, de la mémoire et du contexte.
- Mise en œuvre d'un pipeline RAG avec chunking, embeddings, recherche sémantique et base vectorielle ChromaDB.
- Développement d'un backend Python/FastAPI avec API REST documentées avec OpenAPI et persistance des documents et métadonnées dans MongoDB.
- Développement d'une interface React/Next.js permettant aux chercheurs d'interagir avec l'agent, ses outils et de sélectionner les messages conservés dans le contexte.
- Automatisation de la collecte de métadonnées scientifiques et transmission des résultats de tâches cron par webhooks.
- Gestion d'une application web conteneurisée permettant d'utiliser des LLM installés localement avec LM Studio sur un Mac Studio, avec installation et configuration des modèles.
- Utilisation de vLLM pour lancer et servir des modèles sur une infrastructure HPC équipée de GPU NVIDIA.
- Évaluation de Qwen, Gemma et GLM et de plusieurs quantifications avec Slurm selon la latence, le TTFT, la qualité et la taille du contexte.
- Définition du protocole expérimental, analyse des résultats et rédaction en cours d'un article scientifique comparant les modèles.
- Conteneurisation avec Docker, gestion des sources avec Git et mise en place d'une CI/CD sur GitHub.

Université Karunya — Coimbatore, Inde

Stagiaire ingénieur de recherche en apprentissage par renforcement — Juin 2025 – Sept. 2025

- Développement d'un modèle d'apprentissage par renforcement pour la navigation autonome d'un robot hospitalier, puis déploiement et tests sur Raspberry Pi.

Compétences

Développement	Python, JavaScript, C#, .NET, Java, FastAPI, React, Next.js, Node.js, API REST, OpenAPI
IA générative et agents	LLM, vLLM, API OpenAI, LangChain, prompts, agents multi-étapes, RAG, embeddings, ChromaDB
Data et Machine Learning	Pandas, scikit-learn, SQL, MongoDB, PyTorch, TensorFlow, Deep Learning, RL
Évaluation de LLM	Protocoles expérimentaux, quantification, latence, TTFT, qualité, taille du contexte
Génie logiciel et outils	Linux, Docker, Git/GitHub, CI/CD, Slurm, environnement HPC
Langues	Français natif, anglais courant avec IELTS 7,5, espagnol notions

Formation

ENSC (École nationale supérieure de cognitique, Bordeaux INP) — Bordeaux, France

Diplôme d'ingénieur en intelligence artificielle et sciences cognitives — 2023 – 2026

- Formation en informatique, génie logiciel, intelligence artificielle et sciences cognitives, incluant l'interaction humain-machine, l'ergonomie et l'expérience utilisateur, avec une spécialisation en LLM, TALN et apprentissage profond.