



Frédéric Andrian

Ingénieur IA · Generative AI, LLM, agents et RAG

Bordeaux, France

☎ (+33) 769875327 | ✉ fredericj.andrian@gmail.com | 🌐 AndriantsehoFrederic | 📄 FredericAndriantseho

Profil

Jeune diplômé de l'ENSC, école de Bordeaux INP, je viens de terminer mon stage de fin d'études à INRIA Bordeaux et suis disponible à partir de mi-octobre 2026. J'y ai développé une application associant un agent multi-étapes, un pipeline RAG et des services Python/FastAPI. J'ai aussi déployé des LLM locaux avec vLLM sur GPU NVIDIA, comparé plusieurs modèles et quantifications, puis contribué à un article scientifique. Je souhaite poursuivre la conception et l'industrialisation de solutions reposant sur les LLM, les agents et le RAG.

Expériences professionnelles

INRIA

Bordeaux, France

Stagiaire ingénieur de recherche en IA

Mars 2026 – Septembre 2026

- Conception en autonomie, avec le suivi de mes encadrants, d'un agent IA multi-étapes destiné à aider les chercheurs à trouver des articles scientifiques.
- Construction de l'agent sans framework avec intégration de l'API OpenAI, conception de prompts et gestion des outils, de la mémoire et du contexte.
- Collecte automatisée de documents scientifiques en ligne, préparation et découpage en segments adaptés au pipeline RAG.
- Génération des embeddings et indexation des segments dans la base vectorielle ChromaDB.
- Recherche sémantique des passages pertinents puis intégration du contexte récupéré dans les requêtes adressées au LLM.
- Développement du backend Python/FastAPI avec API REST, OpenAPI et MongoDB, puis intégration avec Docker et GitHub CI/CD.
- Installation et configuration de modèles locaux, puis utilisation de vLLM pour les lancer et les servir sur des GPU NVIDIA.
- Comparaison de Qwen, Gemma et GLM et de plusieurs quantifications sur infrastructure HPC avec Slurm selon la latence, le TTFT, la qualité et la taille du contexte.
- Définition du protocole expérimental, analyse des résultats et contribution à un article scientifique comparant les modèles.

Université Karunya

Coimbatore, Tamil Nadu, Inde

Stagiaire de recherche en apprentissage par renforcement

Juin 2025 – Septembre 2025

- Développement d'un modèle d'apprentissage par renforcement et de son environnement d'entraînement pour la navigation autonome d'un robot hospitalier.
- Déploiement et optimisation du logiciel et du modèle sur un Raspberry Pi embarqué.

Compétences

LLM et agents

API OpenAI, vLLM, LangChain, Qwen, Gemma, GLM, agents multi-étapes, prompts, outils, mémoire, contexte

RAG et recherche sémantique

Découpage, embeddings, recherche vectorielle, ChromaDB, récupération et intégration du contexte

Évaluation de LLM

Protocoles expérimentaux, quantification, latence, TTFT, qualité, taille du contexte

Développement et données

Python, FastAPI, API REST, OpenAPI, MongoDB, SQL, Pandas, Git/GitHub

Déploiement et calcul

Linux, Docker, CI/CD, vLLM, Slurm, HPC, GPU NVIDIA

Machine Learning

PyTorch, TensorFlow, scikit-learn, Deep Learning, Reinforcement Learning, NLP/TALN

Langues

Français natif, anglais courant avec IELTS 7,5, espagnol notions

Formation

ENSC, École nationale supérieure de cognitive, Bordeaux INP

Bordeaux, France

Diplôme d'ingénieur en intelligence artificielle et sciences cognitives

2023 – 2026

- Formation en informatique, génie logiciel, intelligence artificielle et sciences cognitives, avec une spécialisation en LLM, TALN et apprentissage profond.