



Frédéric Andriantseho

Ingénieur IA Agentique · LLM, agents et RAG

Bordeaux, France

☎ (+33) 769875327 | ✉ fredericj.andrian@gmail.com | 🌐 AndriantsehoFrederic |

📄 FredericAndriantseho

Profil

Jeune diplômé de l'ENSC, école de Bordeaux INP, je viens de terminer mon stage de fin d'études à INRIA Bordeaux et suis disponible à partir de mi-octobre 2026. J'y ai transformé un besoin utilisateur en une application fonctionnelle associant un agent IA multi-étapes, ses outils, un pipeline RAG, des services Python/FastAPI, MongoDB et une interface React/Next.js. Le développement de l'agent sans framework m'a permis d'approfondir l'exécution d'outils, la mémoire, le contexte et les workflows autonomes. Je souhaite poursuivre la conception d'agents connectés aux systèmes d'information et approfondir l'orchestration multi-agents au service de cas d'usage métiers concrets chez GBH.

Expériences professionnelles

INRIA

Bordeaux, France

Stagiaire ingénieur de recherche en IA

Mars 2026 – Septembre 2026

- Conception en autonomie, avec le suivi de mes encadrants, d'un agent IA multi-étapes répondant au besoin d'aider les chercheurs à trouver des articles scientifiques.
- Construction de l'agent sans framework d'orchestration afin de maîtriser ses outils, son état, sa mémoire, son contexte et ses enchaînements de tâches.
- Développement d'un mécanisme permettant à l'utilisateur de sélectionner les messages à inclure dans le contexte transmis au LLM afin de contrôler la mémoire de la conversation.
- Intégration de l'API OpenAI et conception de prompts pour adapter le comportement de l'agent et guider la sélection de ses outils.
- Collecte automatisée de documents scientifiques en ligne, préparation et découpage en segments adaptés au pipeline RAG.
- Génération des embeddings, indexation dans ChromaDB et recherche sémantique des passages pertinents pour enrichir le contexte du LLM.
- Développement du backend Python/FastAPI avec API REST, OpenAPI et MongoDB, puis d'une interface React/Next.js destinée aux utilisateurs.
- Création de webhooks transmettant les résultats de tâches cron et intégration des différents outils à l'application.
- Installation de modèles locaux et utilisation de vLLM pour les lancer et les servir sur des GPU NVIDIA.
- Comparaison de Qwen, Gemma et GLM et de plusieurs quantifications selon la qualité, la latence, le TTFT et la taille du contexte.
- Conteneurisation de composants avec Docker et mise en place d'un pipeline CI/CD sur GitHub.

Université Karunya

Coimbatore, Tamil Nadu,

Inde

Stagiaire de recherche en apprentissage par renforcement

Juin 2025 – Septembre 2025

- Développement d'un modèle d'apprentissage par renforcement et de son environnement d'entraînement pour la navigation autonome d'un robot hospitalier.
- Déploiement et optimisation du logiciel et du modèle sur un Raspberry Pi embarqué.

Compétences

Agents IA	Agents multi-étapes, conception d'outils, prompts, état, mémoire, contexte, workflows autonomes, OpenClaw
LLM	API OpenAI, vLLM, Qwen, Gemma, GLM, modèles locaux, quantification, GPU NVIDIA
RAG	Collecte et découpage, embeddings, recherche sémantique, ChromaDB, enrichissement du contexte
Développement et intégration	Python, FastAPI, API REST, OpenAPI, MongoDB, SQL, webhooks, tâches cron
Frameworks	LangChain utilisé dans un projet antérieur
Évaluation	Protocoles expérimentaux, qualité, latence, TTFT, taille du contexte, Slurm, environnement HPC
Génie logiciel	Linux, Docker, Git/GitHub, CI/CD
Langues	Français natif, anglais courant avec IELTS 7,5, espagnol notions

Formation

ENSC, École nationale supérieure de cognitique, Bordeaux INP

Bordeaux, France

Diplôme d'ingénieur en intelligence artificielle et sciences cognitives

2023 – 2026

- Formation en informatique, génie logiciel, intelligence artificielle et sciences cognitives, avec une spécialisation en LLM, TALN et apprentissage profond.