



Frédéric Andrian

Ingénieur IA agentique

☎ (+33) 769875327 | ✉ fredericj.andrian@gmail.com | 🌐 AndriantsehoFrederic | 📄 FredericAndriantseho

Profil

Jeune diplômé de l'ENSC, école de Bordeaux INP, disponible dès que possible, j'ai déjà une expérience du développement d'agents IA de bout en bout. À l'INRIA, j'ai développé en autonomie une application fonctionnelle destinée aux chercheurs, avec un agent Python multi-étapes, des outils, une gestion de la mémoire et du contexte, un pipeline RAG et des API REST. Mes expérimentations sur les LLM ont renforcé mon intérêt pour leur qualité et leur fiabilité. Je souhaite poursuivre la création d'agents utiles aux utilisateurs et continuer à monter en compétences chez Inetum.

Expériences professionnelles

INRIA

Bordeaux, France

Stagiaire ingénieur de recherche en IA

Mars 2026 – Septembre 2026

- Conception en autonomie, avec le suivi de mes encadrants, d'une application et d'un agent IA multi-étapes répondant au besoin d'aider les chercheurs à trouver des articles scientifiques.
- Développement de l'agent en Python sans framework d'orchestration pour comprendre ses mécanismes, avec intégration de l'API OpenAI, gestion des outils, de l'état et de la mémoire.
- Conception de prompts adaptés au cas d'usage et à l'utilisation des outils, avec gestion du contexte et sélection par l'utilisateur des messages à transmettre au LLM.
- Mise en œuvre d'un pipeline RAG avec chunking, embeddings et recherche sémantique dans une base vectorielle ChromaDB.
- Développement d'un backend Python/FastAPI avec API REST documentées avec OpenAPI, persistance MongoDB et interface React/Next.js pour interagir avec l'agent.
- Automatisation de la collecte de métadonnées d'articles scientifiques en ligne et transmission des résultats de tâches cron par webhooks.
- Conteneurisation avec Docker, mise en place d'une CI/CD sur GitHub et gestion d'une application utilisant des LLM installés localement sur un Mac Studio.
- Utilisation de vLLM pour servir des modèles sur une infrastructure HPC équipée de GPU NVIDIA, avec Slurm pour les expérimentations.
- Comparaison de Qwen, Gemma et GLM et de plusieurs quantifications selon la qualité des réponses, la latence, le TTFT et la taille du contexte.
- Définition du protocole expérimental, analyse des résultats et rédaction en cours d'un article scientifique comparant les modèles.
- Évaluation d'OpenCLAW dans un environnement Docker isolé et analyse des risques liés à l'accès autonome de l'agent aux outils et aux fichiers.

Université Karunya

Coimbatore, Inde

Stagiaire de recherche en apprentissage par renforcement

Juin 2025 – Sept. 2025

- Développement d'un modèle d'apprentissage par renforcement et de son environnement d'entraînement pour la navigation autonome d'un robot hospitalier.
- Déploiement et optimisation du logiciel et du modèle sur Raspberry Pi pour des tests en conditions réelles.

Compétences

Agents et LLM

Python, API OpenAI, LangChain, vLLM, prompts, tool calling, agents multi-étapes, mémoire, contexte

Intégrations et données

FastAPI, API REST, OpenAPI, webhooks, MongoDB, SQL, Pandas

RAG

Chunking, embeddings, recherche sémantique, base vectorielle ChromaDB

Évaluation LLM

Protocoles expérimentaux, qualité des réponses, quantification, latence, TTFT, taille du contexte

Développement et outils

React, Next.js, JavaScript, Git/GitHub, Docker, CI/CD, tâches cron, Linux, HPC, Slurm

Machine Learning

PyTorch, TensorFlow, scikit-learn, Deep Learning, apprentissage par renforcement

Langues

Français natif, anglais courant avec IELTS 7,5, espagnol notions

Formation

ENSC (École nationale supérieure de cognitique, Bordeaux INP)

Bordeaux, France

Diplôme d'ingénieur en intelligence artificielle et sciences cognitives

2023 – 2026

- Formation en informatique, génie logiciel et interaction humain-machine, avec une spécialisation en LLM, TALN et apprentissage profond.