



Frédéric Andrian

Architecte IA junior · IA générative, RAG et API

Bordeaux, France

☎ (+33) 769875327 | ✉ fredericj.andrian@gmail.com | 🌐 AndriantsehoFrederic |

📄 FredericAndriantseho

Profil

En fin de cursus d'ingénieur à l'ENSC, école de Bordeaux INP, je viens de terminer mon stage de fin d'études au sein de l'équipe Mnémosyne d'INRIA Bordeaux et suis disponible à partir de mi-octobre 2026. J'y ai développé en autonomie, avec le suivi de mes encadrants, un agent IA multi-étapes sans framework d'orchestration afin d'en maîtriser les outils, l'état, la mémoire et le contexte. J'ai également conçu ses services Python/FastAPI, ses API REST, son pipeline RAG, sa persistance MongoDB et son déploiement conteneurisé. Je souhaite évoluer vers la conception et l'industrialisation de plateformes IA modulaires, fiables et sécurisées.

Expériences professionnelles

INRIA, équipe Mnémosyne

Bordeaux, France

Stagiaire ingénieur de recherche en IA

Mars 2026 – Septembre 2026

- Conception et développement en autonomie, avec le suivi de mes encadrants, d'un agent IA multi-étapes répondant au besoin d'aider les chercheurs à trouver des articles scientifiques.
- Construction de l'agent sans framework d'orchestration afin de comprendre et maîtriser l'exécution des outils, l'état, la mémoire, le contexte et les enchaînements de tâches.
- Intégration de l'API OpenAI et conception des outils utilisés par l'agent pour rechercher des informations et exécuter des tâches successives.
- Développement de services Python/FastAPI, d'API REST documentées avec OpenAPI et de la persistance MongoDB.
- Mise en œuvre d'un pipeline RAG comprenant le chunking, les embeddings, la recherche sémantique et une base vectorielle ChromaDB.
- Conteneurisation de composants avec Docker et mise en place d'un pipeline CI/CD sur GitHub.
- Gestion d'une application web conteneurisée permettant d'utiliser des LLM installés localement sur un Mac Studio, incluant l'installation et la configuration des modèles.
- Évaluation d'OpenClaw dans un environnement Docker isolé avec une attention portée à la fiabilité et à la sécurité des accès autonomes aux outils et aux fichiers.
- Comparaison de Qwen, Gemma et GLM et de plusieurs configurations de quantification sur une infrastructure HPC avec Slurm selon la latence, la TTFT, la qualité et la taille du contexte.
- Définition du protocole expérimental, analyse des résultats et contribution à un article scientifique sur l'évaluation des modèles.

Université Karunya

Coimbatore, Tamil Nadu,
Inde

Stagiaire de recherche en apprentissage par renforcement

Juin 2025 – Sept. 2025

- Conception et comparaison d'une planification de trajectoire déterministe et d'une approche fondée sur l'apprentissage par renforcement pour la navigation autonome d'un robot hospitalier.
- Déploiement et optimisation du logiciel et du modèle d'apprentissage par renforcement sur un Raspberry Pi embarqué.

Compétences

IA générative et agents

LLM, API OpenAI, agents multi-étapes, conception d'outils, état, mémoire, contexte, OpenClaw

RAG et données

Chunking, embeddings, recherche sémantique, ChromaDB, MongoDB, SQL

Développement et intégration

Python, FastAPI, Node.js, API REST, OpenAPI, webhooks

Évaluation de LLM

Qwen, Gemma, GLM, quantification, protocoles expérimentaux, latence, TTFT, qualité, taille du contexte

Déploiement et DevOps

Linux, Docker, Git/GitHub, CI/CD, Slurm, environnements HPC, Raspberry Pi

Machine Learning

PyTorch, Deep Learning, Reinforcement Learning, NLP/TALN

Langues

Français (natif), anglais courant (IELTS 7,5), espagnol (notions)

Formation

ENSC (École nationale supérieure de cognitive, Bordeaux INP)

Bordeaux, France

Diplôme d'ingénieur en intelligence artificielle et sciences cognitives

2023 – 2026