



Frédéric Andrian

Ingénieur IA

☎ (+33) 769875327 | ✉ fredericj.andrian@gmail.com | 🌐 AndriantsehoFrederic | 📄 FredericAndriantseho

Profil

Jeune diplômé de l'ENSC, école de Bordeaux INP, disponible dès que possible. À l'INRIA, j'ai développé en autonomie une application fonctionnelle destinée aux chercheurs, associant un agent IA, un pipeline RAG, un backend Python/FastAPI et une interface React/Next.js. J'ai également géré une application utilisant des LLM locaux et comparé plusieurs modèles selon leur qualité et leurs performances. Je souhaite poursuivre la création de solutions d'IA utiles aux utilisateurs et approfondir leur industrialisation et leur amélioration dans la durée.

Expériences professionnelles

INRIA

Bordeaux, France

Stagiaire ingénieur de recherche en IA

Mars 2026 – Septembre 2026

- Conception en autonomie, avec le suivi de mes encadrants, d'une application et d'un agent IA multi-étapes répondant au besoin d'aider les chercheurs à trouver des articles scientifiques.
- Construction de l'agent sans framework d'orchestration, avec intégration de l'API OpenAI, prompts adaptés au cas d'usage, gestion des outils, de l'état et de la mémoire.
- Mise en œuvre d'un pipeline RAG avec découpage des documents, embeddings et recherche sémantique dans une base vectorielle ChromaDB.
- Développement d'un backend Python/FastAPI avec API REST documentées avec OpenAPI et persistance des documents et métadonnées dans MongoDB.
- Développement d'une interface React/Next.js pour interagir avec l'agent et ses outils, avec sélection par l'utilisateur des messages à inclure dans le contexte du LLM.
- Automatisation de la collecte de métadonnées d'articles scientifiques en ligne et transmission des résultats de tâches cron par webhooks.
- Gestion d'une application web conteneurisée utilisant des LLM installés localement sur un Mac Studio, avec installation et configuration des modèles.
- Conteneurisation de composants avec Docker et mise en place d'une CI/CD sur GitHub.
- Utilisation de vLLM pour servir des modèles sur une infrastructure HPC équipée de GPU NVIDIA, avec Slurm pour les expérimentations.
- Évaluation de Qwen, Gemma et GLM et de plusieurs quantifications selon la qualité des réponses, la latence, le TTFT et la taille du contexte.
- Définition du protocole expérimental, analyse des résultats et rédaction en cours d'un article scientifique comparant les modèles.

Université Karunya

Coimbatore, Inde

Stagiaire de recherche en apprentissage par renforcement

Juin 2025 – Sept. 2025

- Développement d'un modèle d'apprentissage par renforcement et de son environnement d'entraînement pour la navigation autonome d'un robot hospitalier.
- Déploiement et optimisation du logiciel et du modèle sur Raspberry Pi pour des tests en conditions réelles.

Compétences

Développement et API Agents et LLM

Python, FastAPI, API REST, OpenAPI, React, Next.js, JavaScript, webhooks
API OpenAI, LangChain, vLLM, prompts, agents multi-étapes, outils, mémoire, contexte

RAG et données

Chunking, embeddings, recherche sémantique, ChromaDB, MongoDB, SQL, Pandas

Évaluation LLM

Protocoles expérimentaux, quantification, qualité des réponses, latence, TTFT, taille du contexte

Environnements et outils

Linux, Docker, Git/GitHub, CI/CD, tâches cron, utilisation HPC, Slurm, GPU NVIDIA

Machine Learning

PyTorch, TensorFlow, scikit-learn, Deep Learning, apprentissage par renforcement

Langues

Français natif, anglais courant avec IELTS 7,5, espagnol notions

Formation

ENSC (École nationale supérieure de cognitique, Bordeaux INP)

Bordeaux, France

Diplôme d'ingénieur en intelligence artificielle et sciences cognitives

2023 – 2026

- Formation en informatique, génie logiciel et interaction humain-machine, avec une spécialisation en LLM, TALN et apprentissage profond.