



Frédéric Andrian

Ingénieur IA · Systèmes agentiques et évaluation de LLM

Bordeaux, France

☎ (+33) 769875327 | ✉ fredericj.andrian@gmail.com | 🌐 AndriantsehoFrederic | 📄 FrédéricAndriantseho

Profil

Jeune diplômé de l'ENSC, école de Bordeaux INP, disponible dès maintenant, j'ai conçu à INRIA Bordeaux une application associant agent IA, RAG, API Python/FastAPI et interface web. J'ai également comparé plusieurs LLM et quantifications, travaillé sur leur inférence locale et étudié les risques liés aux agents autonomes. Je souhaite approfondir la conception d'architectures IA fiables et la sélection de solutions adaptées aux besoins et aux contraintes techniques, au sein de l'écosystème de cloud de confiance de S3NS.

Expériences professionnelles

INRIA

Bordeaux, France

Stagiaire ingénieur de recherche en IA

Mars 2026 – Septembre 2026

- Conception et développement en autonomie, avec le suivi de mes encadrants, d'une application répondant au besoin d'aider les chercheurs à trouver des articles scientifiques.
- Construction d'un agent multi-étapes sans framework d'orchestration afin de maîtriser ses outils, son état, sa mémoire et ses enchaînements de tâches.
- Intégration de l'API OpenAI, conception de prompts et sélection des messages par l'utilisateur pour contrôler le contexte transmis au LLM.
- Intégration des composants applicatifs avec un backend Python/FastAPI, des API REST documentées avec OpenAPI, MongoDB et une interface React/Next.js.
- Mise en œuvre d'un pipeline RAG avec découpage des documents, embeddings, indexation dans ChromaDB et recherche sémantique.
- Gestion d'une application web conteneurisée utilisant des LLM installés localement sur un Mac Studio, avec installation et configuration des modèles.
- Utilisation de vLLM pour lancer et servir des modèles sur GPU NVIDIA.
- Comparaison de Qwen, Gemma et GLM et de plusieurs quantifications sur infrastructure HPC avec Slurm selon la qualité, la latence, le TTFT et la taille du contexte.
- Définition du protocole expérimental, analyse des résultats et rédaction d'un article scientifique présentant les résultats et les limites des modèles.
- Évaluation d'OpenClaw dans un environnement Docker isolé et analyse des risques liés à l'accès autonome aux outils et aux fichiers.
- Conteneurisation de composants avec Docker et mise en place d'un pipeline CI/CD sur GitHub.

Université Karunya

Coimbatore, Inde

Stagiaire de recherche en apprentissage par renforcement

Juin 2025 – Septembre 2025

- Développement d'un modèle d'apprentissage par renforcement et de son environnement d'entraînement pour la navigation autonome d'un robot hospitalier.
- Déploiement et optimisation du logiciel et du modèle sur un Raspberry Pi afin de le tester en conditions réelles.

Compétences

Agents et LLM

API OpenAI, vLLM, LangChain, agents multi-étapes, outils, prompts, état, mémoire, contexte

RAG

Chunking, embeddings, recherche sémantique, ChromaDB

Évaluation LLM

Protocoles expérimentaux, quantification, qualité, latence, TTFT, taille du contexte

Développement et intégration

Python, FastAPI, API REST, OpenAPI, MongoDB, SQL, React, Next.js

Déploiement et calcul

Linux, Docker, Git/GitHub, CI/CD, Slurm, environnement HPC, GPU NVIDIA

Analyse des risques agentiques

OpenClaw, expérimentation en environnement isolé, accès aux outils et aux fichiers

Langues

Français natif, anglais courant avec IELTS 7,5, espagnol notions

Formation

ENSC, École nationale supérieure de cognitive, Bordeaux INP

Bordeaux, France

Diplôme d'ingénieur en intelligence artificielle et sciences cognitives

2023 – 2026

- Formation en informatique, génie logiciel et IA, avec une spécialisation en LLM, TALN et apprentissage profond.