



Frédéric Andrian

GenAI Engineer · Agents IA et RAG

Bordeaux, France

☎ (+33) 769875327 | ✉ fredericj.andrian@gmail.com | 🌐 AndriantsehoFrederic |

📄 FredericAndriantseho

Profil

En fin de cursus d'ingénieur à l'ENSC, école de Bordeaux INP, je viens de terminer mon stage de fin d'études à Inria Bordeaux et suis disponible dès octobre 2026. J'y ai développé en autonomie un agent IA associant l'API OpenAI, LangChain, un pipeline RAG et des services Python/FastAPI. J'ai aussi comparé plusieurs LLM et configurations de quantification selon leur latence, la qualité des réponses et la taille du contexte, puis documenté ces travaux dans un article scientifique. Je souhaite approfondir la conception et l'industrialisation de solutions GenAI, avec un intérêt particulier pour la gestion du contexte, l'évaluation des modèles et le partage des connaissances.

Expériences professionnelles

Inria

Bordeaux, France

Stagiaire ingénieur de recherche en IA

Mars 2026 – Septembre 2026

- Conception et développement en autonomie, avec le suivi de mes encadrants, d'un agent IA multi-étapes répondant au besoin exprimé par mon tuteur d'aider les chercheurs à trouver des articles scientifiques.
- Intégration de l'API OpenAI et de LangChain avec création et orchestration des outils permettant à l'agent d'exécuter des tâches successives.
- Mise en œuvre d'une architecture RAG comprenant le chunking, les embeddings, la recherche sémantique et une base vectorielle ChromaDB.
- Développement de services et d'API REST en Python/FastAPI avec OpenAPI et MongoDB ainsi que d'une interface React/Next.js destinée aux utilisateurs.
- Comparaison de Qwen, Gemma et GLM ainsi que de plusieurs configurations de quantification afin d'identifier le meilleur compromis entre performances d'inférence et qualité selon l'environnement d'exécution.
- Conteneurisation de certains outils avec Docker et mise en place sur GitHub d'un pipeline CI/CD automatisant l'intégration.
- Responsable d'une application web conteneurisée permettant d'utiliser des LLM installés localement sur un Mac Studio ainsi que de l'installation et de la gestion des modèles.
- Définition du protocole expérimental, analyse des résultats et rédaction d'un article scientifique sur l'évaluation des modèles.

Université Karunya

Coimbatore, Tamil Nadu,

Inde

Stagiaire de recherche en apprentissage par renforcement

Juin 2025 – Sept. 2025

- Conception, développement et comparaison d'une planification de trajectoire déterministe et d'une approche fondée sur l'apprentissage par renforcement pour la navigation autonome d'un robot hospitalier.
- Déploiement et optimisation du logiciel et du modèle d'apprentissage par renforcement sur un Raspberry Pi embarqué.

Compétences

IA générative et agents

LLM, API OpenAI, LangChain, agents multi-étapes, création et orchestration d'outils

RAG et données

Chunking, embeddings, recherche sémantique, ChromaDB, MongoDB, SQL

Sélection et évaluation de LLM

Comparaison de modèles, quantification, protocole expérimental, latence, TTFT, qualité, taille du contexte

Développement

Python, FastAPI, API REST, OpenAPI, React, Next.js, Node.js

Génie logiciel et DevOps

Linux, Docker, Git/GitHub, CI/CD, Slurm, environnement HPC

Machine Learning

PyTorch, Deep Learning, Reinforcement Learning, NLP/TALN

Langues

Français (natif), anglais courant (IELTS 7,5), espagnol (notions)

Formation

ENSC (École nationale supérieure de cognitive, Bordeaux INP)

Bordeaux, France

Diplôme d'ingénieur en intelligence artificielle et sciences cognitives

2023 – 2026

- Formation en informatique, génie logiciel, intelligence artificielle et sciences cognitives, incluant l'interaction humain-machine, l'ergonomie et l'expérience utilisateur, avec une spécialisation en LLM, TALN et apprentissage profond.