

Frédéric **Andrian**

Agent Engineer · LLM, outils et RAG

(+33) 769875327 | fredericj.andrian@gmail.com | AndriantsehenoFrederic |
FredericAndriantseheno

Profil

Jeune diplômé de l'ENSC, école de Bordeaux INP, je suis disponible dès que possible. À l'INRIA, j'ai développé sans framework d'orchestration un agent IA multi-étapes afin de comprendre et maîtriser ses mécanismes : appels d'outils, état, mémoire, contexte, prompts et gestion des résultats. Je l'ai intégré à une application complète associant API, RAG, base vectorielle et interface utilisateur, puis j'ai étudié les risques liés à l'exécution d'outils par des agents. Je souhaite poursuivre dans l'ingénierie agentique et concevoir des assistants robustes, traçables et intégrés aux workflows logiciels.

Expériences professionnelles

INRIA — Bordeaux, France

Stagiaire ingénieur de recherche en IA — Mars 2026 – Septembre 2026

- Analyse d'un besoin de recherche d'articles scientifiques et conception en autonomie d'une application intégrant un agent IA multi-étapes.
- Construction de l'agent sans framework d'orchestration afin de maîtriser la décomposition des tâches, l'enchaînement des étapes et les appels d'outils.
- Intégration de l'API OpenAI, conception de prompts et gestion de l'état, de la mémoire et du contexte conversationnel.
- Mise en œuvre d'une architecture RAG avec chunking, embeddings, recherche sémantique et base vectorielle ChromaDB.
- Développement d'un backend Python/FastAPI avec API REST documentées avec OpenAPI et persistance des documents et métadonnées dans MongoDB.
- Développement d'une interface React/Next.js permettant d'interagir avec l'agent, ses outils et de sélectionner les messages conservés dans le contexte.
- Automatisation de la collecte de métadonnées scientifiques avec tâches cron et transmission des résultats par webhooks.
- Évaluation d'OpenClaw dans un environnement Docker isolé afin d'analyser les risques liés à l'accès de l'agent aux outils et aux fichiers.
- Conteneurisation avec Docker, gestion des sources avec Git et mise en place d'une CI/CD sur GitHub.
- Gestion d'une application web conteneurisée permettant d'utiliser des LLM installés localement avec LM Studio sur un Mac Studio, avec installation et configuration des modèles.
- Utilisation de vLLM pour lancer et servir des modèles sur une infrastructure HPC équipée de GPU NVIDIA.
- Évaluation de Qwen, Gemma et GLM et de plusieurs quantifications avec Slurm selon la latence, le TTFT, la qualité et la taille du contexte.
- Définition du protocole expérimental, analyse des résultats et rédaction en cours d'un article scientifique comparant les modèles.

Université Karunya — Coimbatore, Inde

Stagiaire ingénieur de recherche en apprentissage par renforcement — Juin 2025 – Sept. 2025

- Développement d'un modèle d'apprentissage par renforcement pour la navigation autonome d'un robot hospitalier, puis déploiement et tests sur Raspberry Pi.

Compétences

Développement	Python, JavaScript, C#, .NET, Java, FastAPI, React, Next.js, Node.js, API REST, OpenAPI
IA générative et agents	LLM, vLLM, API OpenAI, LangChain, prompts, agents multi-étapes, RAG, embeddings, ChromaDB
Data et Machine Learning	Pandas, scikit-learn, SQL, MongoDB, PyTorch, TensorFlow, Deep Learning, RL
Évaluation de LLM	Protocoles expérimentaux, quantification, latence, TTFT, qualité, taille du contexte
Génie logiciel et outils	Linux, Docker, Git/GitHub, CI/CD, Slurm, environnement HPC
Langues	Français natif, anglais courant avec IELTS 7,5, espagnol notions

Formation

ENSC (École nationale supérieure de cognitique, Bordeaux INP) — Bordeaux, France

Diplôme d'ingénieur en intelligence artificielle et sciences cognitives — 2023 – 2026

- Formation en informatique, génie logiciel, intelligence artificielle et sciences cognitives, incluant l'interaction humain-machine, l'ergonomie et l'expérience utilisateur, avec une spécialisation en LLM, TALN et apprentissage profond.