



# Frédéric Andrian

Ingénieur IA

☎ (+33) 769875327 | ✉ fredericj.andrian@gmail.com | 🌐 AndriantsehoFrederic | 📄 FrédéricAndriantseho

## Profil

Jeune diplômé de l'ENSC, école de Bordeaux INP, spécialisé en intelligence artificielle et sciences cognitives, je viens de terminer mon stage de fin d'études à INRIA Bordeaux et suis disponible dès que possible. À l'INRIA, j'ai développé une application IA de bout en bout associant un agent multi-étapes, des services Python/FastAPI, un pipeline RAG, MongoDB et une interface React/Next.js. J'ai également conçu ses prompts et ses outils, évalué plusieurs LLM et contribué à un article scientifique. Je souhaite poursuivre le développement de solutions d'IA utiles et robustes.

## Expériences professionnelles

### INRIA

Bordeaux, France

Stagiaire ingénieur de recherche en IA

Mars 2026 - Septembre 2026

- Conception en autonomie, avec le suivi de mes encadrants, d'une application IA fonctionnelle répondant au besoin d'aider les chercheurs à trouver des articles scientifiques.
- Développement d'un backend Python/FastAPI avec API REST documentées avec OpenAPI et stockage des documents et métadonnées dans MongoDB.
- Développement d'une interface React/Next.js pour interagir avec l'agent et ses outils, avec sélection des messages à inclure dans le contexte du LLM.
- Construction d'un agent multi-étapes sans framework d'orchestration, avec API OpenAI, prompts adaptés au cas d'usage, outils, mémoire et gestion du contexte.
- Mise en œuvre d'un pipeline RAG avec chunking, embeddings et recherche sémantique dans une base vectorielle ChromaDB.
- Développement de scripts Python pour collecter des métadonnées d'articles scientifiques en ligne et transmettre les résultats de tâches cron par webhooks.
- Conteneurisation Docker, CI/CD sur GitHub et gestion d'une application utilisant des LLM installés localement sur un Mac Studio.
- Utilisation de vLLM sur HPC avec GPU NVIDIA et comparaison de Qwen, Gemma, GLM et de leurs quantifications selon la qualité, la latence, le TTFT et la taille du contexte.
- Définition du protocole expérimental, analyse des résultats et rédaction en cours d'un article scientifique comparant les modèles.

### Université Karunya

Coimbatore, Inde

Stagiaire de recherche en apprentissage par renforcement

Juin 2025 - Sept. 2025

- Développement d'un modèle d'apprentissage par renforcement et de son environnement d'entraînement pour la navigation autonome d'un robot hospitalier.
- Déploiement et optimisation du logiciel et du modèle sur Raspberry Pi pour des tests en conditions réelles.

## Projet universitaire

### Assistant Machine Learning pour joueurs de League of Legends

Python, Pandas, scikit-learn, Random Forest

- Collecte de données de parties via une API, nettoyage et préparation avec Pandas, puis entraînement d'un modèle Random Forest avec scikit-learn pour assister les joueurs dans leurs décisions.
- Intégration des prédictions dans un agent Discord afin de rendre les résultats accessibles aux utilisateurs.

## Compétences

### Développement

Python, JavaScript, C#, .NET, Java, FastAPI, React, Next.js, Node.js, API REST, OpenAPI

### IA générative et agents

LLM, vLLM, API OpenAI, LangChain, prompts, agents multi-étapes, RAG, embeddings, ChromaDB

### Data et Machine Learning

Pandas, scikit-learn, SQL, MongoDB, PyTorch, TensorFlow, Deep Learning, RL

### Évaluation de LLM

Protocoles expérimentaux, quantification, latence, TTFT, qualité, taille du contexte

### Génie logiciel et outils

Linux, Docker, Git/GitHub, CI/CD, Slurm, environnement HPC

### Langues

Français natif, anglais courant avec IELTS 7,5, espagnol notions

## Formation

### ENSC (École nationale supérieure de cognitique, Bordeaux INP)

Bordeaux, France

Diplôme d'ingénieur en intelligence artificielle et sciences cognitives

2023 - 2026