



Frédéric Andrian

Ingénieur IA · Python, LLM, RAG et applications IA

Bordeaux, France

☎ (+33) 769875327 | ✉ fredericj.andrian@gmail.com | 🌐 AndriantsehoFrederic |

📄 FredericAndriantseho

Profil

Jeune diplômé de l'ENSC, école de Bordeaux INP, disponible à partir de novembre 2026, j'ai développé à INRIA Bordeaux une application IA fonctionnelle associant agent multi-étapes, pipeline RAG, API Python/FastAPI et interface React/Next.js. J'ai également évalué plusieurs LLM et configurations de quantification, puis contribué à la rédaction d'un article scientifique. Je souhaite rejoindre Valeo pour continuer à concevoir des solutions IA adaptées aux besoins des utilisateurs et approfondir leur intégration et leur déploiement dans un environnement industriel.

Expériences professionnelles

INRIA

Bordeaux, France

Stagiaire ingénieur de recherche en IA

Mars 2026 – Septembre 2026

- Conception et développement en autonomie, avec le suivi de mes encadrants, d'une application IA répondant au besoin d'aider les chercheurs à trouver des articles scientifiques.
- Construction d'un agent multi-étapes sans framework d'orchestration avec intégration de l'API OpenAI et gestion des outils, de l'état et de la mémoire.
- Conception de prompts adaptés au cas d'usage et sélection des messages par l'utilisateur pour contrôler le contexte transmis au LLM.
- Mise en œuvre d'un pipeline RAG avec préparation et découpage des documents, génération d'embeddings et indexation dans ChromaDB.
- Recherche sémantique des passages pertinents et intégration du contexte documentaire dans les requêtes au LLM.
- Développement du backend Python/FastAPI, d'API REST documentées avec OpenAPI et du stockage des données dans MongoDB.
- Développement d'une interface React/Next.js permettant aux chercheurs d'utiliser l'agent et ses outils.
- Installation et configuration de LLM locaux, puis utilisation de vLLM pour lancer et servir des modèles sur GPU NVIDIA.
- Comparaison de Qwen, Gemma et GLM et de plusieurs quantifications sur infrastructure HPC avec Slurm selon la qualité, la latence, le TTFT et la taille du contexte.
- Définition du protocole expérimental, analyse des résultats et contribution à la rédaction d'un article scientifique comparant les modèles.
- Conteneurisation de composants avec Docker et mise en place d'un pipeline CI/CD sur GitHub.

Université Karunya

Coimbatore, Inde

Stagiaire de recherche en apprentissage par renforcement

Juin 2025 – Septembre 2025

- Développement d'un modèle d'apprentissage par renforcement et de son environnement d'entraînement pour la navigation autonome d'un robot hospitalier.
- Déploiement et optimisation du logiciel et du modèle sur un Raspberry Pi afin de le tester en conditions réelles.

Compétences

Développement et interfaces

Python, FastAPI, API REST, OpenAPI, React, Next.js

LLM et agents

API OpenAI, prompts, outils, mémoire, contexte, vLLM, LangChain

RAG et données

Chunking, embeddings, recherche sémantique, ChromaDB, MongoDB, SQL, Pandas

Évaluation de modèles

Protocoles expérimentaux, quantification, qualité, latence, TTFT, taille du contexte

Déploiement et calcul

Linux, Docker, Git/GitHub, CI/CD, GPU NVIDIA, Slurm, environnement HPC

Machine Learning

PyTorch, TensorFlow, scikit-learn, Deep Learning, Reinforcement Learning, NLP/TALN

Langues

Français natif, anglais courant avec IELTS 7,5, espagnol notions

Formation

ENSC, École nationale supérieure de cognitive, Bordeaux INP

Bordeaux, France

Diplôme d'ingénieur en intelligence artificielle et sciences cognitives

2023 – 2026

- Formation en informatique, génie logiciel et IA, avec une spécialisation en LLM, TALN et apprentissage profond.