



Frédéric Andrian

Ingénieur IA · Full-stack, agents IA et RAG

☎ (+33) 769875327 | ✉ fredericj.andrian@gmail.com | 🌐 AndriantsehoFrederic | 📄 FredericAndriantseho

Profil

Jeune diplômé de l'ENSC, école de Bordeaux INP, spécialisé en intelligence artificielle et sciences cognitives, je viens de terminer mon stage de fin d'études à INRIA Bordeaux et suis disponible dès que possible. À l'INRIA, j'ai développé une application IA de bout en bout associant un agent multi-étapes, des services Python/FastAPI, un pipeline RAG, MongoDB et une interface React/Next.js. J'ai également conçu ses prompts et ses outils, évalué plusieurs LLM et contribué à un article scientifique. Je souhaite poursuivre le développement de solutions d'IA utiles et robustes.

Expériences professionnelles

INRIA

Bordeaux, France

Stagiaire ingénieur de recherche en IA

Mars 2026 – Septembre 2026

- Conception en autonomie, avec le suivi de mes encadrants, d'une application et d'un agent IA multi-étapes répondant au besoin d'aider les chercheurs à trouver des articles scientifiques.
- Construction de l'agent sans framework d'orchestration avec intégration de l'API OpenAI, conception de prompts et gestion des outils, de l'état, de la mémoire et du contexte.
- Développement d'un backend Python/FastAPI avec API REST documentées avec OpenAPI et persistance MongoDB.
- Développement d'une interface React/Next.js permettant aux chercheurs d'interagir avec l'agent et ses outils.
- Mise en œuvre d'un pipeline RAG avec découpage, embeddings, recherche sémantique et base vectorielle ChromaDB.
- Automatisation de la collecte de métadonnées d'articles scientifiques disponibles en ligne et transmission des résultats de tâches cron par webhooks.
- Gestion d'une application web conteneurisée permettant d'utiliser des LLM installés localement sur un Mac Studio, avec installation et configuration des modèles.
- Utilisation de vLLM pour lancer et servir des modèles sur une infrastructure HPC équipée de GPU NVIDIA.
- Conteneurisation de composants avec Docker et mise en place d'une CI/CD sur GitHub.
- Évaluation de Qwen, Gemma et GLM et de plusieurs quantifications sur infrastructure HPC avec Slurm selon la latence, le TTFT, la qualité et la taille du contexte.
- Définition du protocole, analyse des résultats et contribution à un article scientifique comparant les modèles.

Université Karunya

Coimbatore, Tamil Nadu, Inde

Stagiaire de recherche en apprentissage par renforcement

Juin 2025 – Sept. 2025

- Développement d'un modèle d'apprentissage par renforcement et de son environnement d'entraînement pour la navigation autonome d'un robot hospitalier.
- Déploiement et optimisation du logiciel et du modèle sur un Raspberry Pi embarqué.

Compétences

Développement

Python, JavaScript, C#, .NET, Java, FastAPI, React, Next.js, Node.js, API REST, OpenAPI

IA générative et agents

LLM, vLLM, API OpenAI, LangChain, prompts, agents multi-étapes, RAG, embeddings, ChromaDB

Data et Machine Learning

Pandas, scikit-learn, SQL, MongoDB, PyTorch, TensorFlow, Random Forest, Deep Learning, RL

Évaluation de LLM

Protocoles expérimentaux, quantification, latence, TTFT, qualité, taille du contexte

Génie logiciel et outils

Linux, Docker, Git/GitHub, CI/CD, Slurm, environnement HPC

Langues

Français natif, anglais courant avec IELTS 7,5, espagnol notions

Formation

ENSC (École nationale supérieure de cognitique, Bordeaux INP)

Bordeaux, France

Diplôme d'ingénieur en intelligence artificielle et sciences cognitives

2023 – 2026

- Formation en informatique, génie logiciel, intelligence artificielle et sciences cognitives, incluant l'interaction humain-machine, l'ergonomie et l'expérience utilisateur, avec une spécialisation en LLM, TALN et apprentissage profond.